

Trayectorias de memoria y aprendizaje escolar
bajo escenarios de
exposición digital e inteligencia artificial:
un modelo de simulación basado en agentes para
estudiantes de secundaria en Costa Rica

Agustín Gómez Meléndez

MSc., PhD.

Centro de Investigación Observatorio del Desarrollo (CIOdD)

Universidad de Costa Rica

Observatorio de MIPYMES

Universidad Estatal a Distancia (UNED)

Mayo de 2026

Correspondencia: agomezodd@gmail.com

Versión: Manuscrito para revisión técnica

Nota de autoría: Este artículo forma parte del proyecto “Modelo de Simulación Cognitiva sobre Memoria, Aprendizaje, Redes Sociales e Inteligencia Artificial en Estudiantes de Educación Secundaria de Costa Rica”. Los autores declaran no tener conflictos de interés. El uso de inteligencia artificial generativa en el apoyo analítico y de redacción fue documentado con supervisión humana en todas las etapas.

Resumen

Este artículo presenta el diseño, implementación y resultados de un modelo de simulación basado en agentes (*agent-based model*, ABM) orientado a representar trayectorias plausibles de memoria, aprendizaje, recuperación autónoma y deterioro funcional en estudiantes de educación secundaria de Costa Rica, bajo distintos escenarios de exposición digital, uso de inteligencia artificial (IA) generativa y mediación pedagógica. El modelo —denominado Simulador Cognitivo V4.1— opera sobre 60 centros educativos sintéticos, 1.200 estudiantes-agente, 10 escenarios (E0–E9) y 20 iteraciones Monte Carlo por escenario, con un horizonte temporal de 40 semanas lectivas. La variable central es θ_{IMAE} : una medida latente estandarizada de memoria–aprendizaje derivada del paradigma de la Teoría de Respuesta al Ítem. Los resultados muestran un patrón robusto y diferenciado: los escenarios que integran IA tutora con metacognición, evaluación híbrida y mediación docente eliminan el deterioro funcional moderado y elevan θ_{IMAE} hasta 2.62 desviaciones estándar sobre la línea base, mientras que el uso sustitutivo de IA genera una paradoja evaluativa —alto desempeño aparente con 44.5 % de deterioro funcional moderado— y el choque negativo alcanza 74.4 % de deterioro. La distinción entre IA tutora e IA sustitutiva emerge como el hallazgo sustantivo central del estudio, con implicaciones directas para el diseño de política educativa, la formación docente y la arquitectura de evaluación en la era de la IA generativa. El artículo discute las limitaciones inherentes al uso de datos sintéticos y propone una ruta de validación con datos primarios de estudiantes costarricenses.

Palabras clave: simulación basada en agentes; memoria escolar; inteligencia artificial generativa; recuperación autónoma; deterioro funcional del aprendizaje; Costa Rica; educación secundaria.

Abstract

This article presents the design, implementation, and results of an agent-based model (ABM) aimed at representing plausible trajectories of memory, learning, autonomous

recovery, and functional deterioration among secondary school students in Costa Rica under different scenarios of digital exposure, generative artificial intelligence (AI) use, and pedagogical mediation. The model—Cognitive Simulator V4.1—operates on 60 synthetic educational centers, 1,200 student-agents, 10 scenarios (E0–E9), and 20 Monte Carlo iterations per scenario, over a 40-week academic horizon. The central variable is θ_{IMAE} : a standardized latent measure of memory–learning derived from Item Response Theory. Results show a robust and differentiated pattern: scenarios integrating AI tutoring with metacognition, hybrid assessment, and instructional mediation eliminate moderate functional deterioration and raise θ_{IMAE} up to 2.62 standard deviations above baseline, while substitutive AI use generates an evaluative paradox—high apparent performance with 44.5 % moderate functional deterioration—and the negative shock reaches 74.4 % deterioration. The distinction between tutoring AI and substitutive AI emerges as the central substantive finding, with direct implications for educational policy design, teacher training, and assessment architecture in the era of generative AI. The article discusses limitations inherent to synthetic data and proposes a validation roadmap with primary data from Costa Rican students.

Keywords: agent-based simulation; school memory; generative artificial intelligence; autonomous recovery; functional learning deterioration; Costa Rica; secondary education.

Índice

1. Introducción	5
2. Marco teórico y conceptual	6
2.1. Memoria escolar como proceso multinivel	6
2.2. Desempeño aparente versus aprendizaje real	7
2.3. Exposición digital cognitivamente relevante	7
2.4. Tipos de uso de la inteligencia artificial	8
2.5. Mediación docente como factor protector	8
3. Metodología	9
3.1. Diseño general del modelo	9
3.2. Vector de estado del agente	9
3.3. Especificación matemática del modelo	10
3.3.1. Sueño funcional	10
3.3.2. Atención efectiva	10
3.3.3. Codificación y consolidación	10
3.3.4. Recuperación asistida y autónoma	11
3.3.5. Dependencia funcional de IA	12
3.3.6. Variable latente de memoria–aprendizaje	12
3.4. Escenarios de simulación	13
3.5. Parámetros de sensibilidad	13
4. Resultados	14
4.1. Estadísticas descriptivas por escenario	14
4.2. Prueba de hipótesis global y comparaciones pareadas	15
4.3. La paradoja del desempeño aparente en E3	16
4.4. Trayectorias temporales	16
4.5. Correlaciones entre indicadores	16
4.6. Consistencia entre versiones del simulador	17

5. Discusión	17
5.1. El tipo de uso como variable determinante	17
5.2. La ruta sueño-consolidación	18
5.3. La brecha territorial como multiplicador de riesgos	18
5.4. Implicaciones para el rediseño evaluativo	18
5.5. Blindaje científico: afirmaciones defendibles	19
5.6. Limitaciones	19
6. Ruta de validación y recomendaciones de política educativa	20
6.1. Ruta de validación propuesta	20
6.2. Recomendaciones de política educativa	21
7. Conclusiones	22
Referencias	24

1. Introducción

Costa Rica exhibe una combinación singular de alta conectividad digital y rezagos persistentes en competencias fundamentales. Según el Estado de la Educación (**PEN2025**), los resultados en comprensión lectora, razonamiento matemático y pensamiento analítico continúan por debajo de los estándares esperados para el nivel de desarrollo del país, mientras la penetración de internet móvil supera el 80 % de los hogares (**SUTEL2024**). Esta aparente paradoja —más tecnología, no necesariamente más aprendizaje— obliga a reconceptualizar la pregunta educativa: el problema no es la disponibilidad de dispositivos, sino el tipo, momento, propósito y mediación bajo los cuales se utilizan.

La irrupción de la inteligencia artificial generativa añade una capa de complejidad adicional. Herramientas como los modelos de lenguaje de gran escala (*large language models*) ofrecen posibilidades genuinas de personalización pedagógica, retroalimentación inmediata y accesibilidad cognitiva. Sin embargo, también abren la posibilidad de un fenómeno que este artículo denomina *desempeño aparente sin aprendizaje real*: la producción de tareas formalmente correctas sin consolidación de los procesos cognitivos subyacentes. La encuesta HEPI (**HEPI2026**) evidencia que más del 50 % de los estudiantes universitarios en contextos con alta adopción de IA reportan usar herramientas generativas para completar tareas sin comprenderlas a cabalidad.

Este problema no es meramente tecnológico. Es un problema de diseño pedagógico, de arquitectura evaluativa y de comprensión de los mecanismos cognitivos del aprendizaje. La neurociencia cognitiva documentó extensamente que la consolidación de la memoria a largo plazo requiere procesos activos de recuperación, práctica distribuida, sueño funcional y ausencia de interferencias durante la codificación (**Bjork1992**; **Ebbinghaus1913**). Cuando el entorno digital interrumpe sistemáticamente la atención, reduce el sueño o sustituye el esfuerzo elaborativo, los mecanismos de consolidación se ven comprometidos, aunque el desempeño observable a corto plazo no lo refleje necesariamente.

La pregunta central que orienta este trabajo es: *¿bajo qué combinaciones de exposición a redes sociales, uso nocturno del dispositivo, sueño funcional, autorregulación, mediación docente y tipo de uso de IA generativa emergen trayectorias de mejora, estancamiento o deterioro funcional del aprendizaje escolar en estudiantes de secundaria costarricenses?*

Para abordar esta pregunta, se desarrolló el Simulador Cognitivo V4.1, un modelo basado en agentes con estructura multinivel que traduce los mecanismos cognitivos descritos en la literatura en ecuaciones dinámicas iteradas semana a semana a lo largo de un ciclo lectivo. El modelo no pretende establecer causalidad empírica definitiva, pues los parámetros requieren calibración con datos primarios; su contribución es producir *distribuciones plausibles de trayectorias* bajo supuestos explícitos y controlados, lo que permite identificar qué configuraciones de política educativa merecen ser priorizadas para pilotaje y validación.

El artículo se estructura de la siguiente manera: la sección 2 desarrolla el marco teórico y conceptual; la sección 3 describe el diseño metodológico y la especificación matemática del modelo; la sección 4 presenta los resultados de la simulación; la sección 5 discute las implicaciones, limitaciones y ruta de validación; y la sección 6 formula las conclusiones.

2. Marco teórico y conceptual

2.1. Memoria escolar como proceso multinivel

La memoria escolar no se reduce a recordar información. En la tradición cognitivista, se entiende como un proceso situado que integra al menos cinco subprocesos encadenados: atención, codificación, consolidación, recuperación y transferencia (Bjork1992; Neurociencia2023). Estos procesos no ocurren en aislamiento, sino en interacción permanente con condiciones pedagógicas, emocionales, digitales y contextuales.

La *atención efectiva* es la capacidad de sostener foco sobre una tarea relevante

y resistir interferencias. Su degradación por notificaciones, multitarea digital o déficit de sueño compromete todos los procesos posteriores. La *codificación* implica la transformación de información en representaciones significativas: requiere esfuerzo elaborativo, comprensión profunda y carga cognitiva manejable. La *consolidación* es el proceso por el cual las huellas de memoria se estabilizan en la memoria a largo plazo, dependiente en grado fundamental del sueño y la práctica espaciada (Bjork1992). La *recuperación autónoma*—distinta de la recuperación asistida— es la capacidad de acceder y aplicar el conocimiento sin andamiaje externo, y es el indicador más robusto de aprendizaje genuino.

2.2. Desempeño aparente versus aprendizaje real

Una distinción conceptual central en este artículo es la que separa el *desempeño aparente* del *aprendizaje real*. Una tarea correcta no garantiza aprendizaje consolidado. Con la disponibilidad de herramientas de IA generativa, es posible obtener un producto escolar formalmente correcto —respuesta a una pregunta, resolución de un problema, redacción de un ensayo— sin que el estudiante haya ejecutado los procesos cognitivos que consolidan el aprendizaje.

Este fenómeno no es nuevo: el uso de calculadoras sin comprensión aritmética o de diccionarios sin desarrollo de vocabulario son precedentes históricos. Lo que cambia con la IA generativa es la escala, la sofisticación y la dificultad de detección. El riesgo específico es que los sistemas de evaluación tradicionales, orientados a medir productos finales, sean incapaces de distinguir entre ambos tipos de desempeño.

2.3. Exposición digital cognitivamente relevante

El constructo de Índice de Exposición Digital Cognitivamente Relevante (IEDCR), desarrollado en este modelo, sintetiza cuatro dimensiones: (a) horas de uso de redes sociales y plataformas de video corto durante el horario escolar; (b) multitarea durante tareas académicas; (c) frecuencia e intensidad de interrupciones por notificaciones; y (d) uso nocturno del dispositivo como perturbador del sueño.

Este constructo se diferencia del simple tiempo de pantalla porque incorpora el propósito, el momento y la mediación pedagógica del uso digital.

2.4. Tipos de uso de la inteligencia artificial

El modelo distingue explícitamente dos modalidades de uso de IA generativa con efectos opuestos sobre el aprendizaje:

IA tutora: uso que activa procesos cognitivos activos. Incluye pedir a la IA que explique un concepto de manera alternativa, solicitar ejercicios de práctica para resolverlos de manera autónoma, revisar errores propios con retroalimentación, y verificar la información generada contrastándola con fuentes adicionales. Esta modalidad, cuando se combina con metacognición y práctica sin asistencia, se comporta como factor de apoyo al aprendizaje.

IA sustitutiva: uso que reemplaza el esfuerzo cognitivo. Incluye pedir a la IA que resuelva completamente una tarea, copiar la respuesta generada sin procesarla, evitar la lectura del material original, y omitir la verificación. Esta modalidad produce desempeño aparente elevado pero reduce sistemáticamente la recuperación autónoma y acelera la dependencia funcional.

Esta distinción es el hallazgo sustantivo más importante del modelo y no debe reducirse a una postura tecnofóbica: el problema no es la IA, sino el diseño pedagógico y evaluativo en el que se inserta.

2.5. Mediación docente como factor protector

La evidencia del estudio TALIS (**TALIS2024**) para Costa Rica señala que la claridad instruccional, la frecuencia y calidad de la retroalimentación, y las prácticas de evaluación formativa son predictores robustos de compromiso y logro académico. En el modelo, la mediación docente opera como amortiguador de los efectos negativos de la exposición digital intensiva: un docente que diseña tareas con estructura de IA declarada, combina evaluaciones con y sin asistencia, y proporciona retroalimentación oportuna puede revertir parcialmente el efecto de un entorno digital desfavorable.

3. Metodología

3.1. Diseño general del modelo

El Simulador Cognitivo V4.1 es un modelo basado en agentes con estructura multinivel y dinámica temporal discreta. Cada estudiante-agente i pertenece a un centro educativo j y evoluciona en el tiempo t (medido en semanas lectivas). El modelo opera en ciclos semanales y produce distribuciones de trayectorias bajo supuestos explícitos; no predice destinos individuales ni establece causalidad empírica definitiva.

La configuración técnica del modelo se detalla en la Tabla 1.

Tabla 1: Configuración técnica de la simulación V4.1

Elemento	Valor
Centros educativos sintéticos	60
Estudiantes-agente	1.200
Escenarios	10 (E0–E9)
Iteraciones Monte Carlo	20 por escenario
Horizonte temporal	40 semanas
Unidad de reporte principal	Agregado escenario–iteración, semana 40
Ancla θ_{IMAE} (media T0)	0.5994 ($\sigma = 0,0924$)

3.2. Vector de estado del agente

El vector de estado individual en el tiempo t se define como:

$$\mathbf{X}_{ij}(t) = \left\{ R_0, \text{IEDCR}, S_f, A, C, K, \text{MemAcum}, \text{RecAsist}, \right. \quad (3.1)$$

$$\left. \text{RecAut}, T, U_T, U_S, M, V, D, \mu, \phi \right\}$$

donde R_0 es el rezago inicial, IEDCR el índice de exposición digital, S_f el sueño funcional, A la atención efectiva, C la codificación, K la consolidación, U_T el uso

tutor de IA, U_S el uso sustitutivo de IA, M la metacognición, V la verificación, D la dependencia funcional de IA, μ la motivación y ϕ el apoyo familiar.

3.3. Especificación matemática del modelo

3.3.1. Sueño funcional

El sueño funcional $S_{f,ij}(t)$ combina horas de sueño, uso nocturno del dispositivo, calidad del ciclo de sueño y rutinas de higiene, con efectos diferenciados por centro:

$$S_{f,ij}(t) = s_0 + s_1 H_{sueño,ij}(t) - s_2 U_{noct,ij}(t) - s_3 D_{esc,ij}(t) + s_4 R_{sueño,ij}(t) + u_j + \varepsilon_{ij}(t) \quad (3.2)$$

donde $H_{sueño}$ son las horas efectivas de sueño, U_{noct} el uso nocturno del dispositivo, D_{esc} los despertares nocturnos, $R_{sueño}$ la adherencia a rutinas, u_j el efecto aleatorio de centro y ε_{ij} el error idiosincrático.

3.3.2. Atención efectiva

La atención efectiva $A_{ij}(t)$ es función del entorno digital del estudiante, la calidad del sueño y las condiciones pedagógicas del aula:

$$A_{ij}(t) = a_0 - a_1 IEDCR_{ij}(t) + a_2 S_{f,ij}(t) + a_3 C_{D,j} + a_4 \mu_{ij}(t) - a_5 M_{T,ij}(t) + u_j + \varepsilon_{ij}(t) \quad (3.3)$$

donde $C_{D,j}$ es la claridad instruccional del docente y $M_{T,ij}$ la intensidad de la multitarea digital.

3.3.3. Codificación y consolidación

La codificación $C_{ij}(t)$ transforma la atención en representaciones significativas:

$$C_{ij}(t) = c_0 + c_1 A_{ij}(t) + c_2 E_{ij}(t) + c_3 C_{D,j} + c_4 P_{E,ij}(t) - c_5 CC_{ij}(t) + \varepsilon_{ij}(t) \quad (3.4)$$

donde E_{ij} es el esfuerzo elaborativo, P_E la práctica elaborativa y CC la carga cognitiva. La consolidación $K_{ij}(t)$ opera sobre la codificación previa con modulación por sueño y práctica espaciada:

$$K_{ij}(t) = k_0 + k_1 C_{ij}(t) + k_2 S_{f,ij}(t) + k_3 P_{E,ij}(t) - k_4 I_{ij}(t) + \varepsilon_{ij}(t) \quad (3.5)$$

La memoria acumulada sigue una dinámica de decaimiento con reposición semanal:

$$\text{MemAcum}_{ij}(t+1) = (1 - \lambda_{\text{rec}}) \text{MemAcum}_{ij}(t) + K_{ij}(t) \quad (3.6)$$

con tasa de decaimiento semanal $\lambda_{\text{rec}} \in [0,03, 0,15]$ (valor central: 0.08).

3.3.4. Recuperación asistida y autónoma

Una innovación estructural del modelo es la separación explícita entre recuperación asistida y recuperación autónoma:

$$\text{RecAsist}_{ij}(t) = r_0 + r_1 \text{MemAcum}_{ij}(t) + r_2 AP_{ij}(t) + r_3 \text{Claves}_{ij}(t) + \varepsilon_{ij}(t) \quad (3.7)$$

$$\text{RecAut}_{ij}(t) = q_0 + q_1 \text{MemAcum}_{ij}(t) + q_2 \Omega_{ij}(t) - q_3 D_{ij}(t) + q_4 P_{\emptyset,ij}(t) + \varepsilon_{ij}(t) \quad (3.8)$$

donde $AP_{ij}(t)$ es el apoyo productivo, Ω_{ij} la autonomía cognitiva, D_{ij} la dependencia funcional de IA y $P_{\emptyset}$ la práctica sin asistencia. El apoyo productivo integra las

fuentes legítimas de andamiaje:

$$AP_{ij}(t) = \alpha_1 \text{Mediac}_j + \alpha_2 U_{T,ij}(t) + \alpha_3 \text{Retro}_j(t) \quad (3.9)$$

3.3.5. Dependencia funcional de IA

La dependencia funcional de IA $D_{ij}(t)$ evoluciona dinámicamente como variable de estado acumulativa:

$$D_{ij}(t+1) = D_{ij}(t) + d_1 U_{S,ij}(t) + d_2 \text{Copia}_{ij}(t) - d_3 M_{ij}(t) - d_4 V_{ij}(t) - d_5 P_{\emptyset,ij}(t) + \varepsilon_{ij}(t) \quad (3.10)$$

Esta especificación captura la naturaleza acumulativa de la dependencia: el uso sustitutivo y la copia la incrementan; la metacognición, la verificación y la práctica sin IA la reducen.

3.3.6. Variable latente de memoria–aprendizaje

La variable principal del modelo es $\theta_{\text{IMAE},ij}(t)$, una variable latente estandarizada de memoria–aprendizaje con interpretación en escala de desviaciones estándar respecto al ancla T0:

$$\begin{aligned} \theta_{\text{IMAE},ij}(t) = & \beta_0 + \beta_1 \text{MemAcum}_{ij}(t) + \beta_2 \text{RecAut}_{ij}(t) \\ & + \beta_3 T_{ij}(t) - \beta_4 D_{ij}(t) - \beta_5 R_{0,ij} + u_j + \varepsilon_{ij}(t) \end{aligned} \quad (3.11)$$

donde T_{ij} es la capacidad de transferencia. El deterioro funcional $\Delta\theta_{ij}$ se define como el cambio estandarizado frente al ancla T0:

$$\Delta\theta_{ij} = \theta_{\text{IMAE},ij}(t) - \theta_{\text{IMAE},ij}(0) \quad (3.12)$$

Los umbrales operacionales de deterioro son: leve si $-0,5 \leq \Delta\theta < -0,2$; moderado si $-1,0 \leq \Delta\theta < -0,5$; grave si $\Delta\theta < -1,0$.

3.4. Escenarios de simulación

Se definen diez escenarios que representan combinaciones plausibles de condiciones digitales, pedagógicas y contextuales, resumidos en la Tabla 2.

Tabla 2: Definición sustantiva de los escenarios E0–E9

Escenario	Nombre	Descripción operacional
E0	Base observada	Parámetros calibrados sin intervención adicional
E1	Alta exposición digital	Mayor IEDCR y multitarea sin cambios pedagógicos
E2	Uso nocturno alto	Ruta sueño–consolidación por uso nocturno
E3	IA sustitutiva	Uso sustitutivo, copia y baja verificación
E4	IA tutor con metacognición	IA tutora, verificación y práctica autónoma
E5	Mediación docente alta	Mayor claridad docente y retroalimentación
E6	Brecha territorial	Menor infraestructura, apoyo y mayor rezago
E7	Evaluación híbrida	Tareas con IA declarada y pruebas sin IA
E8	Intervención integral	IA tutora, alfabetización, sueño, mediación y nivelación
E9	Choque negativo	Alta exposición, bajo sueño, baja mediación, alto rezago

3.5. Parámetros de sensibilidad

Los parámetros temporales centrales del modelo, con sus rangos de sensibilidad, se detallan en la Tabla 3.

Tabla 3: Parámetros temporales centrales y rangos de sensibilidad

Parámetro	Bajo	Central	Alto	Justificación
λ_{cod} (diario)	0.20	0.40	0.60	Decaimiento de codificación
λ_{rec} (semanal)	0.03	0.08	0.15	Decaimiento de recuperación
λ_{trans} (semanal)	0.00	0.03	0.08	Estabilidad de transferencia
$U_{\text{noct}} \rightarrow S_f$	0.15	0.30	0.45	Efecto del dispositivo nocturno
$\text{IEDCR} \rightarrow A$	0.15	0.35	0.50	Interferencia digital y multitarea
$U_S \rightarrow D$	0.10	0.35	0.50	Incremento de dependencia por IA sustitutiva

Nota. Los rangos reflejan incertidumbre paramétrica; los valores centrales fueron utilizados en la corrida principal V4.1.

4. Resultados

4.1. Estadísticas descriptivas por escenario

La Tabla 4 presenta los indicadores principales al final del horizonte de simulación (semana 40) para los diez escenarios. Los resultados están reportados como media con intervalo de confianza del 95 % sobre las 20 iteraciones Monte Carlo.

Tabla 4: Indicadores principales de la simulación V4.1 en semana 40

Escenario	θ_{IMAE} (media $\pm$ IC95)	Rec. autónoma	Desempeño ap.	Deterioro mod.
E8 Intervención integral	$2,624 \pm 0,004$	0.610	0.636	0.0 %
E7 Evaluación híbrida	$2,040 \pm 0,004$	0.565	0.585	0.0 %
E4 IA tutor metacognición	$1,930 \pm 0,005$	0.559	0.604	0.0 %
E5 Mediación docente alta	$1,902 \pm 0,004$	0.544	0.575	0.0 %
E0 Base observada	$0,995 \pm 0,005$	0.480	0.522	2.9 %
E1 Alta exposición digital	$0,475 \pm 0,005$	0.442	0.505	7.2 %
E6 Brecha territorial	$0,455 \pm 0,004$	0.447	0.484	8.7 %
E2 Uso nocturno alto	$0,330 \pm 0,005$	0.433	0.481	7.6 %
E3 IA sustitutiva	$-0,784 \pm 0,007$	0.389	0.606	44.5 %
E9 Choque negativo	$-2,182 \pm 0,005$	0.302	0.485	74.4 %

Nota. El valor en negrita en E3 señala la paradoja del desempeño aparente: similar al de E4 a pesar de que θ_{IMAE} es 2.71 DE inferior.

El ordenamiento por θ_{IMAE} es consistente con la lógica del modelo: $E8 > E7 > E4 > E5 > E0 > E1 > E6 > E2 > E3 > E9$. Esta jerarquía se mantiene estable en todas las iteraciones Monte Carlo, con variaciones menores al 1 % entre corridas.

4.2. Prueba de hipótesis global y comparaciones pareadas

El ANOVA entre escenarios para la semana 40 arroja $F(9, 190) = 343,710,4$, $p < 0,001$, $\eta^2 = 0,9999$. Este estadístico no debe interpretarse como efecto causal empírico poblacional, sino como *validación interna* de que los diez escenarios configurados producen trayectorias estadísticamente diferenciadas bajo los parámetros actuales. Dado que las comparaciones se realizan sobre medias agregadas por iteración —con varianza muy reducida— los tamaños de efecto deben leerse como indicadores de separación computacional, no como estimaciones de efecto para poblaciones reales.

Las comparaciones pareadas más relevantes respecto a la línea base E0 se presentan en la Tabla 5.

Tabla 5: Comparaciones pairwise seleccionadas frente a la línea base E0

Comparación	$\Delta\theta$	Cohen d	valor- p	Sig.
E0 vs. E1 Alta exposición	+0,52	+45,7	$< 10^{-53}$	***
E0 vs. E2 Uso nocturno	+0,66	+61,8	$< 10^{-58}$	***
E0 vs. E3 IA sustitutiva	+1,78	+132,4	$< 10^{-71}$	***
E0 vs. E4 IA tutora	-0,94	-83,3	$< 10^{-63}$	***
E0 vs. E5 Mediación docente	-0,91	-90,0	$< 10^{-65}$	***
E0 vs. E6 Brecha territorial	+0,54	+53,9	$< 10^{-56}$	***
E0 vs. E7 Evaluación híbrida	-1,05	-99,0	$< 10^{-66}$	***
E0 vs. E8 Intervención integral	-1,63	-161,2	$< 10^{-74}$	***
E0 vs. E9 Choque negativo	+3,18	+279,0	$< 10^{-83}$	***
E8 vs. E9 (polos opuestos)	+4,81	+451,9	$< 10^{-91}$	***

Nota. Los signos positivos indican que E0 supera al comparador; negativos que el comparador supera a E0. *** $p < 0,001$.

4.3. La paradoja del desempeño aparente en E3

El escenario de IA sustitutiva (E3) constituye el hallazgo estadísticamente más provocador. A la semana 40, E3 registra un desempeño aparente de 0.606, prácticamente idéntico al de E4 (IA tutora, 0.604), pero con una $\theta_{\text{IMAE}} = -0,784$ frente a $\theta_{\text{IMAE}} = 1,930$ en E4. La diferencia es $\Delta\theta = 2,71$ desviaciones estándar, con un tamaño de efecto de separación computacional $d = 198$.

Esta divergencia entre desempeño aparente y aprendizaje real cristaliza en una tasa de deterioro funcional moderado del 44.5 % para E3, frente al 0 % en E4. En términos sustantivos: bajo condiciones de uso sustitutivo, casi la mitad de los estudiantes-agente muestra signos de deterioro funcional del aprendizaje aunque sus tareas observables sean correctas. Este resultado subraya la necesidad de instrumentos de evaluación que no se limiten al producto final.

4.4. Trayectorias temporales

Las trayectorias de θ_{IMAE} a lo largo de las 40 semanas revelan patrones dinámicos diferenciados. El escenario base E0 alcanza un plateau en torno a $\theta \approx 1,0$ aproximadamente en la semana 15. Los escenarios protectores (E4, E5, E7, E8) muestran crecimiento sostenido durante todo el horizonte, con aceleración perceptible a partir de la semana 8. En contraste, E3 y E9 exhiben pendientes negativas pronunciadas desde las primeras semanas, con E9 alcanzando $\theta \approx -2,2$ en la semana 40, lo que corresponde a una pérdida de más de 3 desviaciones estándar respecto a la línea base.

4.5. Correlaciones entre indicadores

La matriz de correlaciones entre indicadores a la semana 40 muestra una fuerte asociación positiva entre θ_{IMAE} y la recuperación autónoma ($r \approx 0,99$), así como con la transferencia de conocimiento. La brecha entre recuperación asistida y autónoma, la dependencia funcional de IA y los índices de deterioro se correlacionan negativamente con θ_{IMAE} . Esta estructura de correlaciones es consistente con el marco

teórico: las intervenciones que fortalecen la autonomía y la transferencia operan como factores protectores del aprendizaje a largo plazo.

4.6. Consistencia entre versiones del simulador

La corrida V2.3 —ejecutada sobre tres escenarios con escala de anclaje diferente— reportó el mismo orden sustantivo: $E8 > E4 > E0$, con mejoras de 15.7 % y 11.4 % respectivamente respecto a la base. Aunque las magnitudes absolutas no son comparables por el cambio de escala, la estabilidad direccional entre V2.3 y V4.1 refuerza la coherencia interna del modelo y reduce la probabilidad de que los resultados sean artefactos de la especificación paramétrica.

5. Discusión

5.1. El tipo de uso como variable determinante

El hallazgo más robusto y relevante del modelo es que no existe un efecto universal de la IA sobre el aprendizaje. Lo que diferencia las trayectorias no es la presencia o ausencia de herramientas de IA, sino el tipo de uso, el diseño pedagógico en el que se inscribe y la presencia de prácticas metacognitivas y de verificación. Esta conclusión no es tecnofóbica —no propone restringir la IA— ni tecnosolucionista —no propone que la IA sea suficiente por sí misma— sino que señala la centralidad del diseño pedagógico.

Esta distinción tiene implicaciones directas para las políticas educativas de integración tecnológica en Costa Rica. El TALIS 2024 (**TALIS2024**) señala que la formación docente en uso pedagógico de IA es limitada, y el estudio de la UNED (**UNED2026**) evidencia que los estudiantes reconocen usar IA de manera sustitutiva sin haber recibido orientación clara sobre sus implicaciones para el aprendizaje. El simulador sugiere que esta brecha de formación tiene costos cognitivos no triviales.

5.2. La ruta sueño–consolidación

El escenario E2 ilustra un mecanismo frecuentemente subestimado en la política educativa: la ruta que conecta el uso nocturno de dispositivos con la reducción del sueño funcional, la degradación de la consolidación mnémica y, finalmente, la reducción de la recuperación autónoma. Con $\Delta\theta = -0,66$ respecto a la base, E2 muestra que el uso nocturno es, en términos de efecto sobre el aprendizaje, más perjudicial que el aumento general de la exposición digital durante el día (E1, $\Delta\theta = -0,52$). Este resultado es coherente con la evidencia en neurociencia del sueño que establece al ciclo sueño–vigilia como condición necesaria para la consolidación de la memoria episódica y semántica (Bjork1992; Neurociencia2023).

5.3. La brecha territorial como multiplicador de riesgos

El escenario E6 exhibe una dinámica particular: los estudiantes en contextos de mayor rezago inicial, menor infraestructura y menor apoyo no solo parten de una posición más baja, sino que tienen menor capacidad de aprovechar intervenciones protectoras cuando estas no consideran sus condiciones específicas. Esto sugiere que las intervenciones pedagógicas diseñadas para contextos urbanos con infraestructura robusta pueden tener efectos atenuados o nulos en contextos de brecha territorial, reforzando la importancia de la estratificación por zona, modalidad y condición del centro en cualquier piloto de política educativa.

5.4. Implicaciones para el rediseño evaluativo

La paradoja del desempeño aparente documentada en E3 tiene una implicación directa para la arquitectura de evaluación. Si los sistemas evaluativos se limitan a medir productos finales —tareas, informes, ejercicios resueltos— sin distinguir si la producción fue acompañada de procesos cognitivos activos, los instrumentos de evaluación se convierten en señales ruidosas o engañosas del aprendizaje real. El modelo sugiere que una evaluación robusta en la era de la IA generativa debe combinar: (a) tareas donde el uso de IA es declarado y evaluado como competencia

crítica; (b) pruebas de recuperación autónoma sin asistencia; (c) evaluación de transferencia a contextos nuevos; y (d) rúbricas de metacognición que valoren el proceso, no solo el producto.

5.5. Blindaje científico: afirmaciones defendibles

La Tabla 6 sistematiza las afirmaciones que este modelo permite formular y las que deben evitarse, como condición de integridad metodológica.

Tabla 6: Matriz de afirmaciones defendibles y no defendibles

Dimensión	Afirmación defendible	Afirmación que debe evitarse
Causalidad	Los escenarios muestran trayectorias plausibles bajo supuestos explícitos	La IA o las redes causan deterioro cognitivo en estudiantes costarricenses
Medición	θ_{IMAE} es una variable latente operacional de memoria-aprendizaje	θ_{IMAE} es una prueba clínica de daño cognitivo
IA generativa	El tipo de uso diferencia los efectos: tutoría/metacognición vs. sustitución	Toda IA mejora o toda IA perjudica el aprendizaje
Estadística	ANOVA y pairwise indican separación interna de escenarios simulados	Los tamaños de efecto son estimaciones poblacionales definitivas
Política pública	E8, E7 y E4 son candidatos prioritarios para pilotaje y validación	E8 debe implementarse sin piloto ni calibración empírica
Generalización	Los resultados orientan hipótesis y diseño de intervención	Los porcentajes son prevalencias nacionales reales

5.6. Limitaciones

El modelo presenta limitaciones que deben ser explicitadas con rigor:

Datos sintéticos: los 60 centros y 1.200 estudiantes-agente son sintéticos, derivados de distribuciones calibradas a partir de estadísticas institucionales (**MEP2025**;

SUTEL2024), no de mediciones directas de estudiantes reales. Los resultados no pueden interpretarse como prevalencias nacionales ni sustentar inferencias causales sin calibración empírica previa.

Número de iteraciones Monte Carlo: las 20 iteraciones por escenario son suficientes para una primera lectura exploratoria, pero el informe técnico y la literatura recomiendan 50–100 iteraciones para reportes con inferencia más robusta.

Variables omitidas: el modelo no incorpora salud mental, dinámicas de grupo de pares, contagio social del comportamiento digital, ni factores socioeconómicos de alta resolución. Estas omisiones pueden sesgar los parámetros cuando se calibre con datos primarios.

Hiperparámetros no calibrados: los valores centrales de los parámetros (Tabla 3) son especificaciones iniciales informadas por la literatura pero no estimadas de datos costarricenses. La calibración con datos T0–T1 es el paso crítico antes de cualquier generalización.

6. Ruta de validación y recomendaciones de política educativa

6.1. Ruta de validación propuesta

Se propone una ruta de validación en seis pasos secuenciales:

Fase 1. Revisión experta: validar constructos, pesos iniciales y escenarios con especialistas en educación, estadística, neurociencia, psicometría e inteligencia artificial. Documentar el grafo acíclico dirigido (DAG) y el conjunto mínimo de covariables de ajuste.

Fase 2. Piloto cognitivo: aplicar entrevistas cognitivas con $n \approx 30$ estudiantes para depurar ítems de exposición digital, uso de IA, sueño y metacognición. Calcular el Índice de Validez de Contenido ($IVC \geq 0,78$) por ítem.

Fase 3. Piloto cuantitativo T0: levantar una base con $n = 300\text{--}600$

estudiantes en 15–30 centros estratificados por zona, modalidad y condición de conectividad. Incluir encuesta de 35–45 minutos con prueba cognitiva breve, tarea de transferencia y registro de sueño.

Fase 4. Validación psicométrica: estimar confiabilidad, estructura factorial (CFA/PLS), parámetros IRT/Rasch, análisis de funcionamiento diferencial de ítems (DIF) e invarianza por sexo, zona y modalidad. Obtener θ_{IMAE} calibrado.

Fase 5. Medición diferida y calibración dinámica: incluir submuestra a 24–48h y, si es posible, a 10 semanas. Ajustar λ_{rec} , λ_{cod} y parámetros de mediación con datos observados. Ejecutar 50–100 iteraciones Monte Carlo.

Fase 6. Simulación robusta y política educativa: correr el simulador calibrado, reportar percentiles y rangos de incertidumbre, priorizar escenarios para implementación piloto y formular guía de política para el Ministerio de Educación Pública.

6.2. Recomendaciones de política educativa

A partir de los resultados del modelo, se derivan ocho recomendaciones priorizadas:

Priorizar E8 como piloto integral. El escenario de intervención integral combina IA tutora, metacognición, evaluación híbrida, regulación del sueño, mediación docente y nivelación. Sus resultados son los más robustos del conjunto y eliminan el deterioro funcional simulado. Debe implementarse en un piloto con diseño experimental o cuasi-experimental antes de escalar.

Usar E4 como alternativa escalable. Cuando los recursos sean limitados, la combinación de IA tutora con bitácora de verificación, práctica sin asistencia y rúbricas de uso responsable es la opción de mínima inversión con mayor impacto simulado.

Rediseñar la arquitectura evaluativa. Incorporar, en todos los niveles, una combinación de tareas con IA declarada y pruebas de recuperación autónoma sin IA. Evaluar proceso, metacognición y transferencia, no únicamente el producto final.

Atender la higiene del sueño como variable educativa. Incluir módulos de higiene digital y sueño funcional en la formación docente y en los programas de orientación estudiantil. La evidencia simulada sugiere que el uso nocturno tiene mayor impacto negativo que el uso diurno intensivo.

Fortalecer la mediación docente. Priorizar en la formación docente el diseño de tareas con IA, la retroalimentación formativa y la evaluación de la autonomía cognitiva. E5 demuestra que la mediación docente sola produce mejoras equivalentes a E4.

Focalizar intervenciones en contextos de brecha territorial. Estratificar cualquier piloto por zona, modalidad y condición del centro. E6 evidencia que la brecha territorial modifica la respuesta a las intervenciones.

Implementar declaraciones formativas de uso de IA. Incorporar plantillas de declaración de uso de IA en actividades escolares, con enfoque formativo y no punitivo: herramienta usada, propósito, parte resuelta sin IA, verificación realizada y aprendizaje logrado.

Calibrar con datos primarios antes de generalizar. Ninguna extrapolación poblacional es válida antes de completar el piloto T0–T1. Los porcentajes de deterioro simulado son escenarios orientativos, no prevalencias nacionales.

7. Conclusiones

Este artículo presentó el Simulador Cognitivo V4.1, un modelo basado en agentes con estructura multinivel diseñado para analizar trayectorias plausibles de memoria, aprendizaje y deterioro funcional en estudiantes de educación secundaria de Costa Rica bajo distintas configuraciones de exposición digital, uso de IA generativa y mediación pedagógica. Los resultados de la simulación, ejecutada sobre 60 centros sintéticos, 1.200 estudiantes-agente y 10 escenarios con 20 iteraciones Monte Carlo, arrojan tres conclusiones sustantivas.

Primera: el tipo de uso de IA —tutora versus sustitutiva— es el factor que más diferencia las trayectorias de aprendizaje, con una separación de 2.71 desviaciones

estándar entre E4 y E3. No existe un efecto universal de la IA: el mismo conjunto de herramientas puede comportarse como factor de apoyo o como vector de deterioro funcional dependiendo del diseño pedagógico y evaluativo en el que se inserta.

Segunda: la paradoja del desempeño aparente no es un riesgo teórico sino un patrón modelizable y cuantificable. E3 muestra que es posible tener desempeño observable similar al de E4 con 44.5 % de deterioro funcional moderado versus 0 %. Esta paradoja invalida la lógica de evaluación basada exclusivamente en productos finales.

Tercera: la intervención integral (E8) —que combina todos los mecanismos protectores— es la más eficaz en términos de θ_{IMAE} y recuperación autónoma, pero requiere recursos y coordinación simultánea de múltiples dimensiones. Para contextos con recursos limitados, E4 y E7 son alternativas viables con impactos sustantivos.

Las limitaciones del modelo —datos sintéticos, parámetros no calibrados con datos primarios costarricenses y número reducido de iteraciones Monte Carlo— son condiciones provisionales, no estructurales. La ruta de validación propuesta, que parte del piloto cognitivo y avanza hacia la calibración psicométrica y la simulación robusta, ofrece un camino operativamente viable para transformar este prototipo en un instrumento de política educativa con validez empírica.

En un contexto en que la inteligencia artificial generativa es ya una realidad cotidiana en las aulas costarricenses, la pregunta no es si los estudiantes usarán IA sino bajo qué condiciones ese uso apoya o socava el aprendizaje escolar. Este modelo ofrece un primer marco operativo y cuantitativo para responder esa pregunta con rigor científico.

Referencias

Bjork, R. A., & Bjork, E. L. (1992). A new theory of disuse and an old theory of stimulus fluctuation. En A. Healy, S. Kosslyn & R. Shiffrin (Eds.), *From learning processes to cognitive processes: Essays in honor of William K. Estes* (Vol. 2, pp. 35–67). Lawrence Erlbaum Associates.

Centro de Investigación en Comunicación (CICOM-UCR). (2024). *Nuestras apps de cada día 2024*. Universidad de Costa Rica.

Consejo Nacional de Rectores & Programa Estado de la Nación. (2025). *Décimo Estado de la Educación 2025*. CONARE-PEN. <https://estadonacion.or.cr/educacion/>

DataReportal. (2026). *Digital 2026: Costa Rica*. Global Digital Insights. [Fuente complementaria para contexto digital; no usada para calibración de parámetros.]

Ebbinghaus, H. (1913). *Memory: A contribution to experimental psychology* (H. A. Ruger & C. E. Bussenius, Trans.). Teachers College Press. (Obra original publicada en 1885)

Gómez Meléndez, A. (2026). *Modelo de simulación cognitiva sobre memoria, aprendizaje, redes sociales e inteligencia artificial: documento metodológico unificado*. Centro de Investigación Observatorio del Desarrollo, Universidad de Costa Rica.

Higher Education Policy Institute (HEPI) & Kortext. (2026). *Student Generative AI Survey 2026*. HEPI Report 199. <https://www.hepi.ac.uk>

Ministerio de Educación Pública (MEP). (2025). *Nómina de centros educativos 2025*. San José, Costa Rica.

Organización para la Cooperación y el Desarrollo Económicos (OCDE). (2024). *TALIS 2024: Nota del participante – Costa Rica*. OCDE. <https://www.oecd.org/education/talis/>

Rasch, G. (1960). *Probabilistic models for some intelligence and attainment tests*. Danish Institute for Educational Research.

Rodríguez-Zúñiga, M., Sancho-Blanco, G., & Sánchez-Castro, D. (2026). Percepción del uso de inteligencia artificial en estudiantes de química de la UNED: estudio diagnóstico. *Tecnología en Marcha*, 39(1), 1–14. <https://doi.org/10.18845/tm.v39i1.8316>

Superintendencia de Telecomunicaciones (SUTEL). (2024). *Estadísticas del sector de telecomunicaciones 2024*. San José, Costa Rica. <https://sutel.go.cr/estadisticas>

Universidad Estatal a Distancia (UNED). (2026). *Informe metodológico sobre percepción estudiantil de inteligencia artificial y orientación docente*. UNED.

Nota de reproducibilidad: el código fuente del Simulador Cognitivo V4.1, los archivos de parámetros por escenario (formato JSON), las semillas aleatorias, las tablas de resultados y los gráficos están disponibles en el repositorio del proyecto. Los resultados reportados corresponden a la corrida con semilla base documentada en el archivo `INFORME_TECNICO_V4_1.txt`, generado el 7 de mayo de 2026.