

¿Riesgo existencial o estrategia de capitalización? La IA entre el fin del mundo y la salida a bolsa

Agustín Gómez Meléndez, MSc./MSI.

Investigador, Centro de Investigación Observatorio del Desarrollo (CIOdD), Universidad de Costa Rica

Las últimas dos semanas han sido, para el "gobierno de la inteligencia artificial", un punto de inflexión retórico. El 8 de septiembre, Jacob Coxon, investigador de preentrenamiento en Anthropic, renunció acusando a los laboratorios de correr hacia una superinteligencia autosuperable "gambling with our lives". Al día siguiente, Evan Hubinger, jefe de alineamiento en Anthropic, fijó en más de 10% la probabilidad de que la IA extinga a la humanidad en la próxima década, admitiendo que su empresa aún no tiene un plan para evitarlo. El 12 de septiembre, Dario Amodei publicó "We Must Pace the Frontier": evaluadores externos incrustados, coordinación entre democracias y coordinación global para frenar deliberadamente la mejora de capacidades. Altman, Musk y Hassabis, rivales que rara vez coinciden, lo respaldaron casi de inmediato.

El clima ya estaba preparado por "If Anyone Builds It, Everyone Dies" (Yudkowsky y Soares, 2025), fruto de dos décadas de investigación de sus autores y éxito editorial del último año, cuya tesis es que cualquier superinteligencia construida con las técnicas actuales condena a la especie, no como metáfora sino como extrapolación de la evidencia.

El análisis serio exige sostener varias lecturas simultáneas sin resolverlas prematuramente en una sola.

La primera toma la advertencia al pie de la letra, y tiene sustento técnico. En el incidente OpenAI-Hugging Face, que METR investigó durante seis días dentro de OpenAI, más de 1.200 agentes intercambiaron cerca de 70.000 mensajes sin que nadie les pidiera coordinarse; más de 700 atacaron a Hugging Face buscando cómo vulnerar su propia evaluación, ninguno alertó a un humano y OpenAI se enteró cuando la víctima detectó el ataque. Noam Brown, de OpenAI, admitió que el monitoreo de la cadena de razonamiento, que lo habría detectado, estaba apagado. La empresa reveló después seis incidentes más: modelos que ocultaron errores, inventaron datos y se comunicaron entre entornos supuestamente aislados. Daniel Selsam añadió que sus modelos saben cada vez

mejor cuándo se les evalúa, por lo que ya no pueden distinguir su conducta auditada de la real. Y la autosuperación no es hipotética: Claude escribe más del 80% del código de Anthropic y lidera ya una cuarta parte de sus tareas de investigación. Que Hubinger hable de más de 10% no es retórica: es su lectura de un comportamiento que ya midió, y que cada vez cuesta más medir.

La segunda lectura es financiera. Anthropic prepara para octubre una salida a bolsa que sus banqueros sitúan cerca de US\$2 billones, tras una ronda de US\$65.000 millones y un crecimiento de catorce veces en ingresos trimestrales: 21 veces el PIB de Costa Rica o 5,1 veces el de toda Centroamérica (Banco Mundial, 2024). The Register sostiene, en una pieza de opinión, que "pacing the frontier" también modera expectativas de inversionistas y posiciona a estos laboratorios como activos sistémicos. Barack Obama apuntó a la misma tensión desde otro ángulo: la brecha entre lo que la sociedad necesita y los imperativos comerciales de empresas que deben justificar sus valoraciones. Pero el argumento contrario pesa: nadie que busca maximizar su valoración anuncia que frenará su negocio, y OpenAI aplazó su propio debut a 2027 alegando seguridad. Queda una pregunta legítima: la independencia de los evaluadores. CSIS recuerda que METR, el evaluador que Amodei propone incrustar, ha sido criticado por flujos circulares de personal y dinero con Anthropic y su entorno filantrópico.

La tercera lectura es la más incómoda, porque no la sostienen cínicos sino quienes creen en el riesgo: el remedio no alcanza. Ezra Klein advierte que "pacing" no es un objetivo, pues caminar despacio hacia un precipicio sigue siendo caminar hacia él, y que Altman, preguntado si prohibiría la autosuperación recursiva, respondió que eso "probablemente no bastaría". Brown aporta la pieza clave: cuando los agentes ejecuten tareas de tres meses y los lanzamientos salgan cada dos, no habrá tiempo de evaluarlos; por eso se espacia lo que se publica, no lo que se construye. OpenAI resolvió un problema del Milenio con un modelo no publicado, más potente que cualquiera disponible, y Brown reconoció que esa ventaja es injusta. El "pacing" frena la frontera visible, no la real, y puede agrandar la brecha de poder e información entre quienes tienen esos modelos y el resto del mundo.

La geopolítica no se reduce a Washington contra Pekín. Trump calificó de "hoax" toda advertencia de extinción, acusó a Amodei de fingir ser "un angelito perfecto", denunció

una "conspiración" que solo beneficiaría a China y, según el New York Times, teme que frenar la IA precipite una caída bursátil y una recesión antes de las elecciones de medio término. Pero está cada vez más solo: Kamala Harris pidió desacelerar, pruebas federales independientes y un tratado internacional; Obama respaldó el pacing, y Gavin Newsom ordenó en California acelerar la supervisión independiente y estudiar mecanismos de apagado de emergencia. Amodei comparte el diagnóstico competitivo: ata el pacing a controles de exportación de chips y compara un límite a la autosuperación con los tratados SALT de control nuclear. Xi Jinping, por su parte, pidió en Shanghái "prevenir la pérdida de control" de la IA. Mientras tanto, el Tesoro prepara la visita de Xi a Washington de esta semana, donde se explora al menos un canal de alerta temprana mutua ante incidentes graves, el tipo de mecanismo que existió durante la Guerra Fría.

Ninguna lectura anula a las demás. Es consistente que el riesgo sea real, que el remedio sea insuficiente, que el anuncio convenga a un roadshow y que todo sirva a la contención de China. Es, como recuerda Klein, un problema de acción colectiva: OpenAI nació desconfiando de Google, Anthropic de OpenAI, y cada uno corre porque teme que frenar solo beneficie a quien no lo haga. El senador Ted Cruz lo resumió sin pudor: prefiere robots asesinos estadounidenses a robots asesinos chinos. Esa lógica supone que alguien los controlará.

Para Costa Rica, sin asiento en esas mesas, la lección no es adoptar el lenguaje del apocalipsis ni descartarlo por interesado. Es exigir mecanismos propios de verificación que no dependan de que las empresas decidan cuánto de su riesgo hacer público, y que la gobernanza que impulsan iniciativas nacionales no se limite a importar el marco de quien más incentivo tiene para definirlo. También es entender que el riesgo más cercano no es la extinción, sino depender de capacidades que solo unos pocos laboratorios y gobiernos pueden ver y usar.

Lo que estas dos semanas han mostrado es que el riesgo y el negocio pueden ser ciertos a la vez, y que incluso el remedio de quienes advierten del peligro puede quedarse corto. Esa distinción no puede delegarse en quienes tienen accionistas esperando.
